UNIVERSIDAD AUSTRAL

Licenciatura en Ciencia de Datos

PROCESAMIENTO AVANZADO DE IMÁGENES

Trabajo Práctico N.º 2

Integrantes

Cortesi Neri, Exequiel Andres

Fernández Perrier, Gregorio

Malatini, Santino

Año 2026

Índice general

1. Problema 1. Monedas y dados 3

1.1. Preprocesamiento y bordes 3

1.2. Segmentación morfológica 4

1.3. Separación de monedas y dados 5

1.4. Agrupamiento de monedas por tamaño 6

1.5. Detección de puntos en dados 7

1.6. Resultados y análisis 8

2. Problema 2. Detección de patentes 9

2.1. Detección y localización de placas 9

2.2. Segmentación de caracteres 10

2.3. Estudio del caso img03.png 11

2.4. Visualización de las doce imágenes 12

2.5. Resultados globales 13

1. Problema 1. Monedas y dados

La primera consigna exige segmentar automáticamente los objetos de la escena, clasificar los tipos de monedas y determinar el número visible en la cara superior de cada dado. La solución sigue un flujo basado en bordes y morfología: imagen original → suavizado → detección de contornos → máscara binaria → análisis geométrico → agrupamiento de monedas o conteo de puntos.

1.1. Preprocesamiento y detección de bordes

La imagen se carga en color y se convierte a escala de grises para trabajar con una sola intensidad por píxel. Luego se aplica un filtro gaussiano con ventana de 9 × 9, que atenúa ruido y pequeñas texturas. Sobre la imagen suavizada se ejecuta el detector de bordes Canny con umbrales 20 y 80.

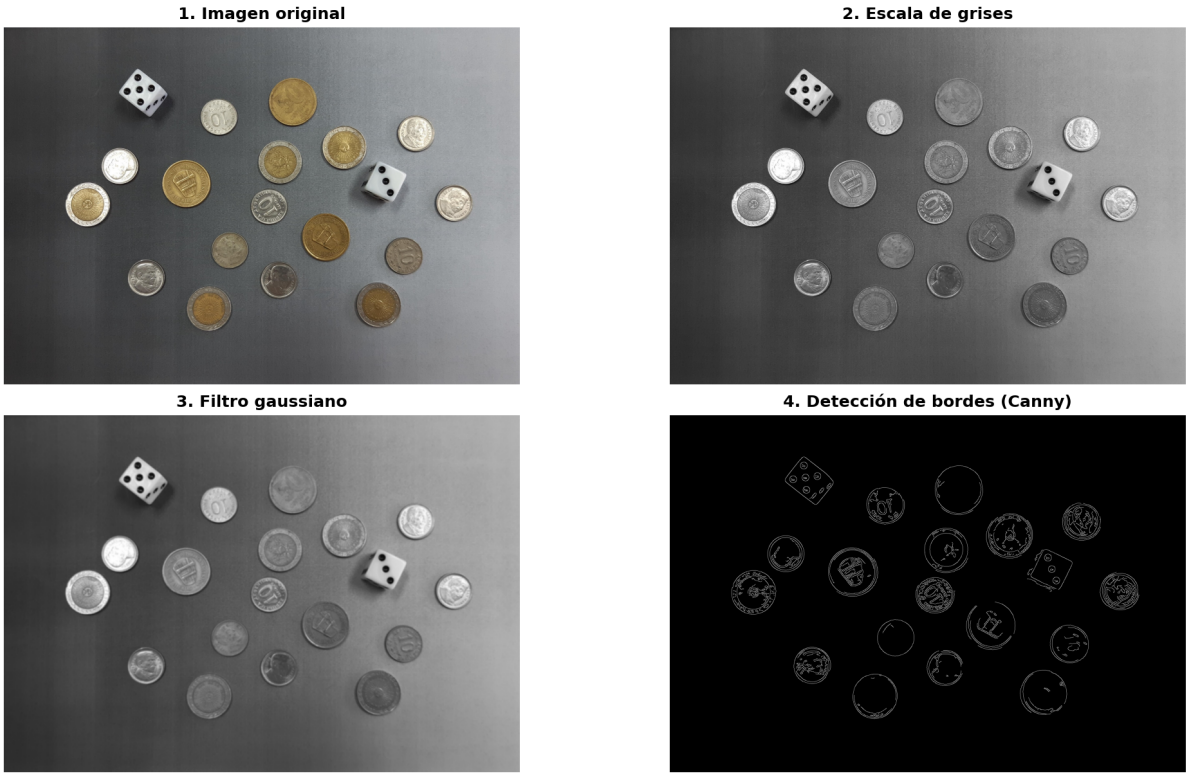


Figura 1. Secuencia de preprocesamiento: imagen original, grises, suavizado gaussiano y bordes Canny.

La elección de bordes, en lugar de una binarización global de intensidades, permite capturar límites de los objetos aun cuando el fondo tenga un gradiente de iluminación. Sin embargo, las inscripciones de las monedas también generan bordes internos, por lo que se requiere una etapa posterior de consolidación.

1.2. Segmentación mediante operaciones morfológicas

Los bordes detectados se dilatan con un elemento estructurante elíptico de 11 × 11, aplicando tres iteraciones. Esta operación busca cerrar discontinuidades y formar contornos externos conectados. Después se usa floodFill desde el fondo para completar los huecos cerrados y producir regiones rellenas.

A continuación se efectúan tres erosiones con el mismo elemento estructurante para compensar el engrosamiento provocado por la dilatación. Finalmente, una apertura morfológica con elemento elíptico de 25 × 25 elimina componentes pequeños y suaviza la máscara.

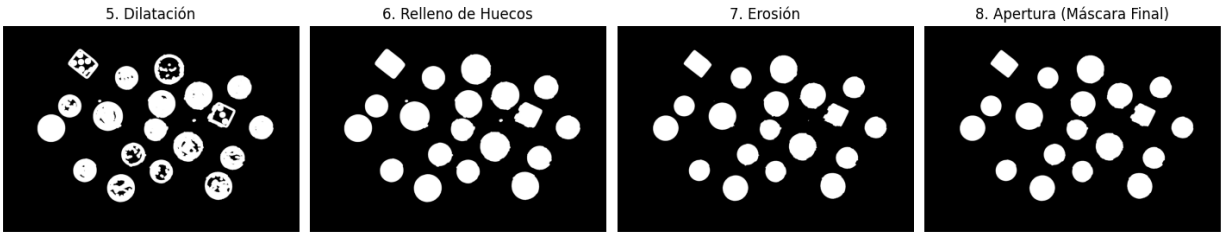


Figura 2. Transformaciones morfológicas empleadas para construir la máscara de segmentación final.

La máscara resultante se emplea para extraer contornos externos. Su calidad condiciona todas las etapas posteriores: una región unida indebidamente o una moneda fragmentada altera el cálculo de forma y área.

1.3. Separación geométrica de monedas y dados

A partir de los contornos externos se descartan regiones de área igual o inferior a 1.500 píxeles². Para cada candidato se calcula su envolvente convexa, la caja delimitadora y un factor de forma definido como $F = P^2/A$, donde P es el perímetro y A el área de la envolvente. En un círculo ideal $F \approx 4\pi \approx 12{,}57$; objetos menos circulares suelen dar valores superiores.

El script asigna la etiqueta «moneda» cuando $F < 13{,}5$ y «dado» en caso contrario. La Figura 3 muestra las cajas azules y verdes resultantes. Es una clasificación geométrica, sin entrenamiento supervisado ni reconocimiento de denominaciones.

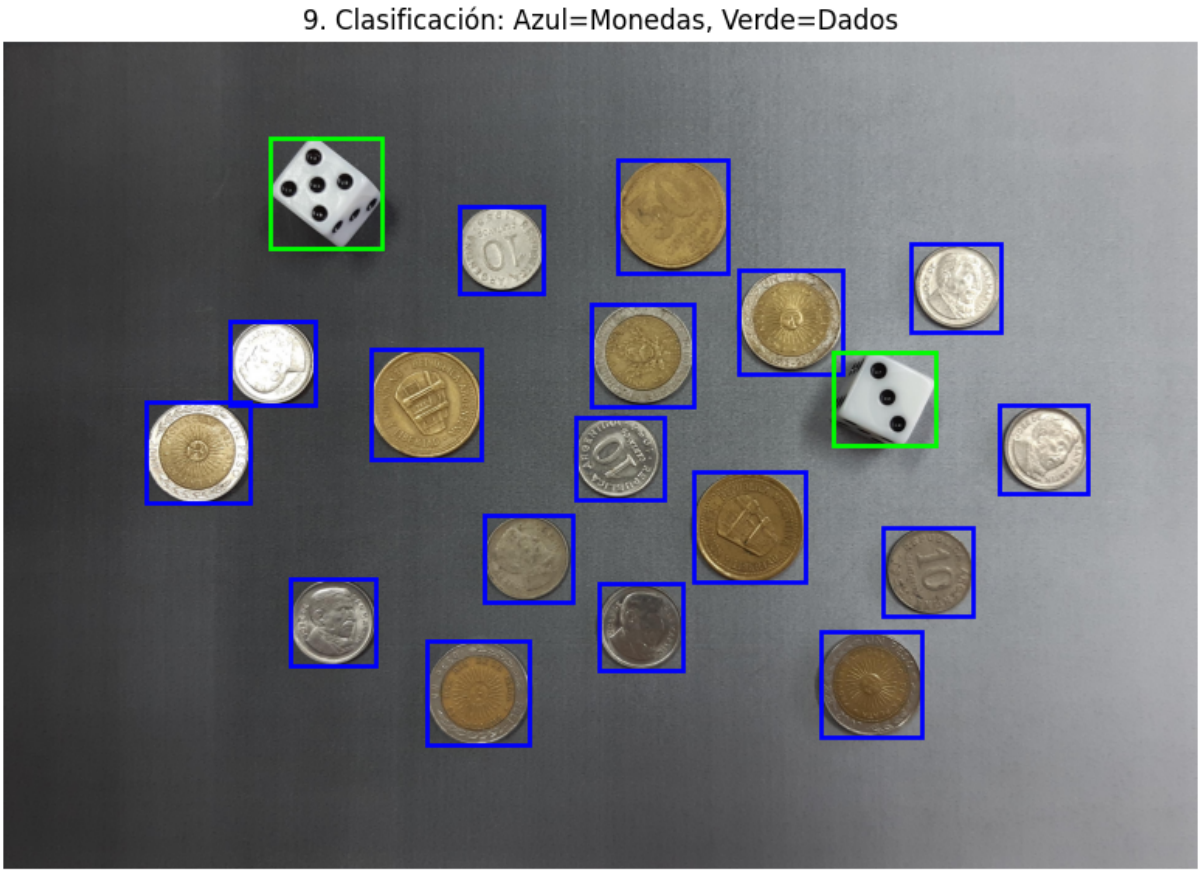


Figura 3. Clasificación por factor de forma. Azul: regiones etiquetadas como monedas. Verde: regiones etiquetadas como dados.

Este criterio permite distinguir las formas predominantes, pero no evita que monedas con máscaras irregulares o regiones fusionadas sean clasificadas como dados.

1.4. Agrupamiento de monedas por tamaño

Las regiones clasificadas como monedas se representan mediante su área. Se aplica K-Means para reunir monedas de dimensiones semejantes, sin definir de antemano el número definitivo de grupos. Para elegir K, el código utiliza Gap Statistic: compara la inercia observada con la esperada en conjuntos de referencia aleatorios y explora hasta cuatro grupos.

En esta ejecución, el procedimiento seleccionó K = 3. Los grupos se ordenan por el área de sus centroides y reciben nombres de tamaño: pequeño, mediano y grande. El resultado se visualiza con recuadros de distintos colores.

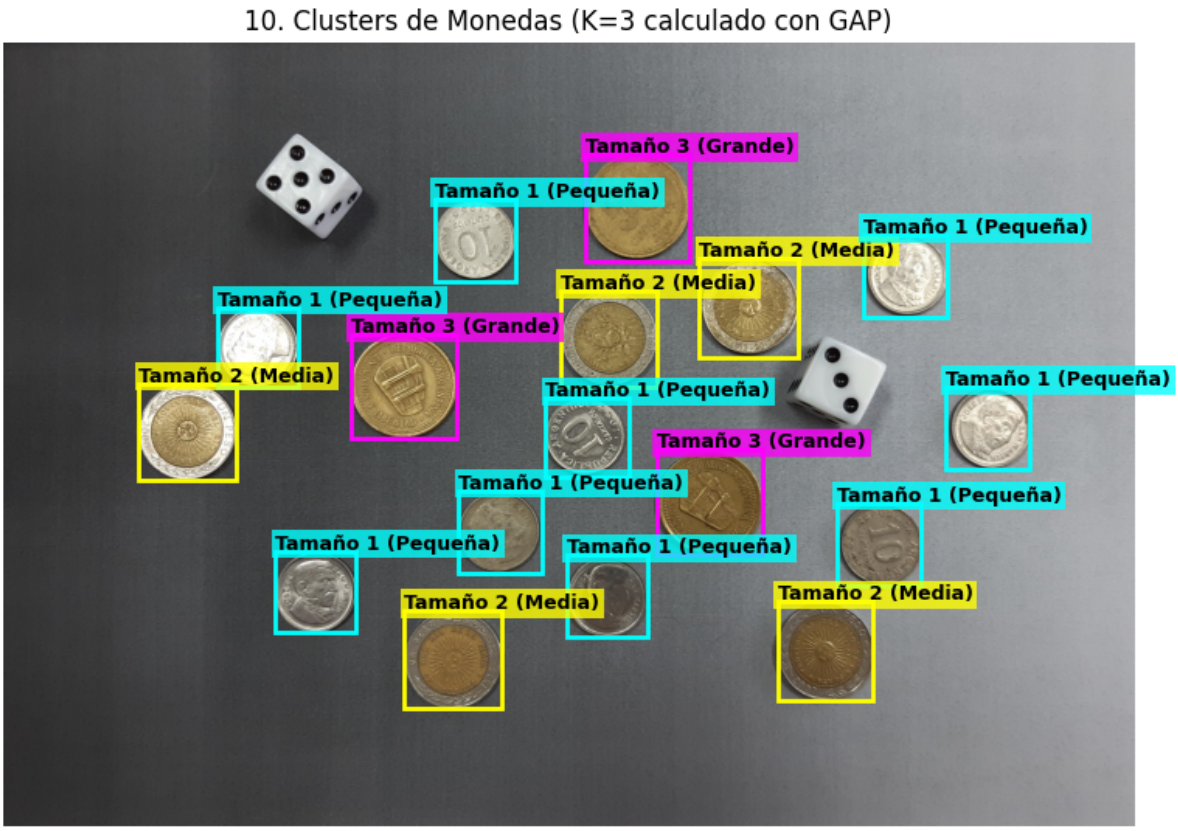


Figura 4. Agrupación de las regiones etiquetadas como monedas mediante K-Means y Gap Statistic (K = 3).

Grupo asignado	Cantidad
Tamaño 1 (pequeña)	8
Tamaño 2 (media)	4
Tamaño 3 (grande)	2

Alcance del resultado: el agrupamiento distingue tamaños relativos, no identifica de manera directa el valor nominal de cada moneda; además, su entrada depende de la clasificación geométrica previa.

1.5. Identificación y conteo de puntos en los dados

Para cada región clasificada como dado se recorta una región de interés (ROI) con un pequeño margen. Se crea una máscara interior a partir de la envolvente convexa y se erosiona para evitar interferencias de los bordes del objeto. Sobre la ROI se usa suavizado gaussiano, Canny (40 y 120), dilatación, relleno de huecos y erosión.

Los componentes resultantes se consideran puntos válidos solo si su área está entre 500 y 5.000 píxeles² y si su factor de forma P^2/A se encuentra entre 10 y 18. La cantidad de componentes aceptados se interpreta como el valor visible del dado.

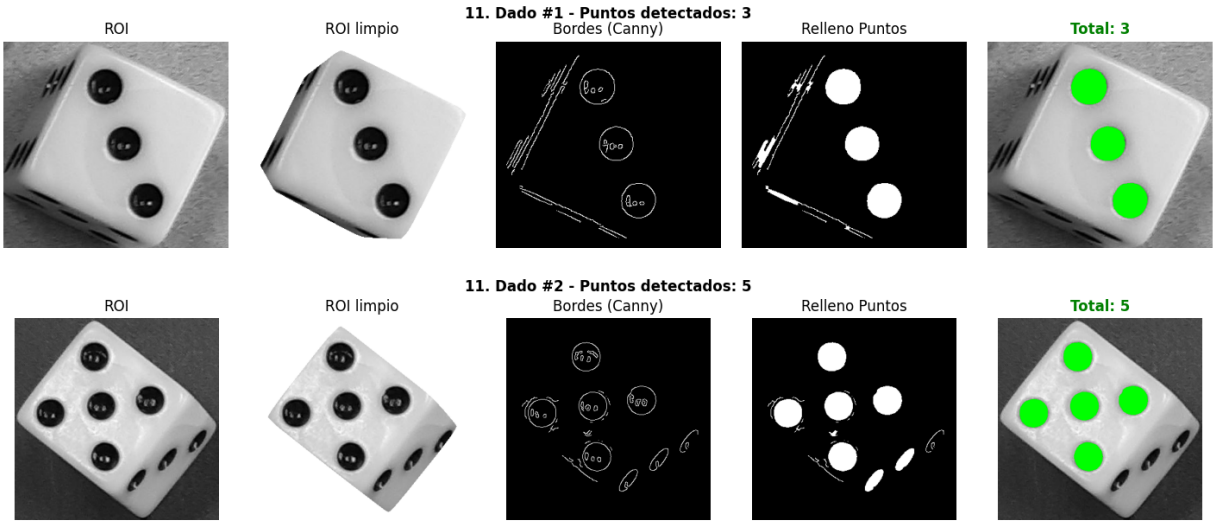


Figura 5. Seguimiento individual de las cuatro regiones candidatas a dado. Dos son dados reales (3 y 5 puntos); las otras dos corresponden a falsos positivos (0 puntos).

La restricción a la máscara interior ayuda a evitar bordes laterales, pero el método depende de la segmentación inicial y de umbrales de área adaptados al tamaño de los puntos en esta imagen.

1.6. Resultados y análisis del Problema 1

La inspección de la imagen original permite identificar un total de 17 monedas y 2 dados. Al ejecutar el algoritmo, se obtuvieron 18 regiones segmentadas, de las cuales 14 fueron clasificadas como monedas y 4 como dados. Sin embargo, únicamente 2 de las regiones identificadas como dados corresponden a dados reales, mientras que las otras 2 representan clasificaciones incorrectas de monedas o regiones asociadas a ellas.

En cuanto a la clasificación de monedas, el algoritmo determinó automáticamente la existencia de 3 grupos según sus áreas, utilizando K-Means y el método Gap Statistic. Como resultado, se identificaron 8 monedas pequeñas, 4 medianas y 2 grandes. Esta clasificación permitió diferenciar los objetos según sus características geométricas, aunque no fue suficiente para reconocer sus denominaciones monetarias.

Por otro lado, el procesamiento de los dados permitió detectar correctamente los valores de sus caras superiores, correspondientes a 3 y 5 puntos. Al analizar las 4 regiones clasificadas inicialmente como dados, se obtuvieron los conteos de 0, 3, 0 y 5 puntos. Esto demuestra que el procedimiento de detección y conteo de puntos funcionó correctamente sobre los dos dados reales, aunque la clasificación inicial incorporó dos falsos positivos.

En términos generales, los resultados muestran que el algoritmo logró segmentar y clasificar gran parte de los objetos presentes en la imagen, aunque presentó algunas limitaciones. Entre ellas se destacan la posible unión de objetos próximos durante la segmentación y la dificultad para distinguir correctamente monedas y dados utilizando únicamente el factor de forma. Estas limitaciones explican por qué la cantidad de monedas identificadas no coincide con la cantidad real presente en la imagen.

Finalmente, la clasificación de monedas por tamaño constituye una aproximación útil para diferenciarlas según sus características morfológicas. Sin embargo, para lograr una clasificación por denominación monetaria sería necesario incorporar información adicional, como el color, la textura o los diseños presentes en sus superficies.

2. Problema 2. Detección de patentes

El segundo problema consiste en localizar automáticamente la placa patente en cada una de doce fotografías y segmentar sus caracteres. El programa opera sin una coordenada fija de búsqueda: explora componentes de la imagen completa y selecciona grupos cuya distribución sea compatible con una fila de caracteres.

2.1. Binarización y detección de candidatos a placa

Cada fotografía se convierte a escala de grises y se binariza con cv2.THRESH_BINARY. En lugar de usar un único umbral para todas las imágenes, el programa recorre valores entre 40 y 228 con paso 2 y selecciona el primero que permite encontrar un grupo de seis candidatos, o uno de cinco como alternativa.

Los componentes conectados se obtienen con conectividad 8. Se filtran según área (entre 15 y 200 píxeles²), relación altura/ancho (entre 1,5 y 3,5) y altura (de 8 a 25 píxeles). Luego se buscan alineaciones horizontales de cinco o seis componentes, considerando separación, coherencia vertical y proporción total del grupo.



Figura 6. Ejemplo con img05.png: conversión a grises, umbralización, filtrado de componentes y agrupación espacial.

La localización obtenida corresponde al rectángulo que abarca el conjunto de caracteres candidatos; por lo tanto, la detección se basa en la geometría del texto y no en reconocer visualmente el marco exterior de la placa.

2.2. Recorte y segmentación individual de caracteres

Una vez localizado el grupo, se estima la altura típica de los componentes y se amplía ligeramente su caja para obtener una ROI. Sobre ese recorte se realiza una segunda búsqueda de umbral, también de 40 a 228 en pasos de 2. Se seleccionan los componentes de altura compatible con la mediana previa, relación alto/ancho adecuada y área suficiente.

El programa prioriza una segmentación con seis componentes; si no la encuentra, conserva una solución parcial de cinco. Cuando una caja es demasiado alta, puede ajustar sus límites verticales utilizando como referencia un componente vecino. Finalmente ordena las cajas de izquierda a derecha y visualiza cada carácter por separado.



Figura 7. Ejemplo de recorte, segunda binarización, delimitación individual y visualización ampliada de caracteres (img05.png).

Esta etapa realiza segmentación de caracteres, no OCR: la salida son imágenes o regiones de cada símbolo, sin asignar automáticamente letras ni números.

2.3. Caso particular: img03.png

En img03.png, la primera búsqueda trabaja con un umbral A = 106 y encuentra inicialmente un grupo de cinco componentes. Al recortar la región y ejecutar la segunda búsqueda, selecciona un umbral B = 116 y obtiene seis componentes para la segmentación final.

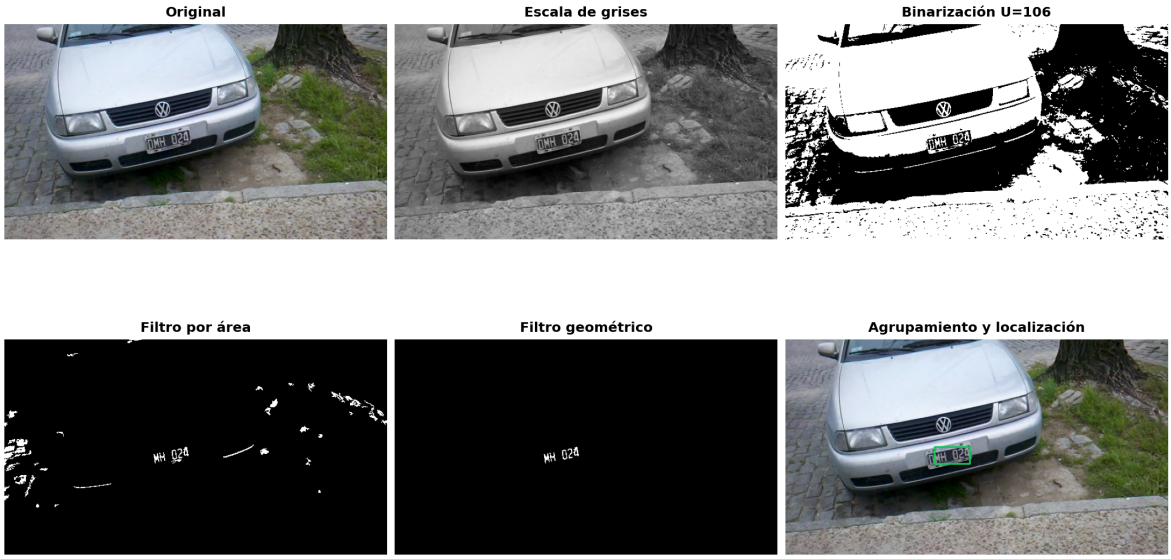


Figura 8. Localización inicial de la patente en img03.png, con cinco candidatos agrupados.



Figura 9. Recorte de img03.png y resultado de la segunda etapa, con seis componentes segmentados.

2.4. Visualización de las doce imágenes

La siguiente composición reúne, para las doce fotografías, un recorte ampliado de la región localizada y las cajas correspondientes a los seis componentes que devuelve el algoritmo. Permite inspeccionar de manera conjunta la coherencia de las detecciones y posibles defectos en los límites de las cajas.



Figura 10. Galería de resultados desde img01.png hasta img12.png. Las cajas verdes indican los componentes seleccionados como caracteres.

La figura muestra consistencia en el número de componentes extraídos, aunque la exactitud de sus contornos debe evaluarse visualmente: un componente detectado no implica, por definición, que el carácter quede aislado de manera perfecta.

2.5. Resultados globales del Problema 2

El procesamiento de las 12 imágenes permitió localizar automáticamente una región candidata a patente en cada una de ellas. Posteriormente, mediante las etapas de segmentación y filtrado, se obtuvieron 6 componentes finales por imagen, alcanzando un total de 72 caracteres segmentados.

Durante la primera etapa, el algoritmo seleccionó automáticamente un umbral de binarización para identificar los posibles caracteres de las patentes. Los valores utilizados variaron entre 56 y 146, dependiendo de las características de iluminación y contraste de cada fotografía. En 11 de las 12 imágenes se identificaron inicialmente 6 componentes candidatos, mientras que en la imagen img03.png se detectaron solamente 5.

En la segunda etapa, se realizó una nueva umbralización sobre la región de interés correspondiente a cada patente, con el objetivo de mejorar la separación de sus caracteres. En la mayoría de las imágenes se mantuvo el umbral utilizado inicialmente, mientras que en img03.png y img11.png fue necesario seleccionar valores diferentes. Particularmente, en img03.png, este ajuste permitió pasar de 5 componentes candidatos a 6 componentes finales.

En términos generales, el algoritmo consiguió detectar una región candidata a patente en las 12 imágenes y obtener los 72 componentes esperados, correspondientes a 6 por fotografía. Estos resultados muestran que la combinación de umbralización, análisis de componentes conectados y criterios geométricos permitió abordar imágenes con diferentes condiciones de iluminación, tamaños y posiciones de las patentes.

Sin embargo, es importante señalar que la obtención de 6 componentes por imagen no garantiza que todos los caracteres hayan sido segmentados correctamente. El porcentaje del 100 % que presenta el programa corresponde a la cantidad de componentes obtenidos respecto de los 72 esperados, y no a una evaluación individual de la precisión de cada segmentación. Para comprobar completamente la calidad de los resultados sería necesario comparar los caracteres extraídos con una referencia previamente validada.